

Leitura Automática de Placa de Equipamentos

Sprint 1 — Relatório Técnico

Integrante	RM
Arthur Baptista dos Santos	565346
João Pedro de Moura Dutra Franco	561738
Nelson Félix Neto	565603

Grupo: FORZY
2025 — Turma de Inteligência Artificial

1. Descrição do Problema e Contexto de Aplicação

Em ambientes industriais, laboratoriais e logísticos, cada equipamento possui uma placa de identificação metálica ou adesiva contendo dados críticos para operação, manutenção e rastreabilidade: número de série, código do equipamento, modelo, fabricante, data de fabricação, tensão nominal, potência, frequência e grau de proteção IP.

A leitura manual dessas placas é lenta, sujeita a erros de transcrição e difícil de escalar em grandes plantas industriais. O projeto FORZY propõe uma solução de Visão Computacional para automatizar esse processo, capturando, localizando, interpretando e extraíndo os dados das placas de forma rápida e confiável.

Informações que precisam ser extraídas:

- Número de Série (SN)
- Tensão nominal (V)
- Potência (kW)
- Frequência (Hz)
- Grau IP
- Data de Fabricação
- Código do Equipamento
- Modelo e Fabricante

2. Levantamento dos Desafios Visuais

Desafio	Descrição
Iluminação variável	Ambientes industriais têm luz artificial inconsistente, gerando sub e superexposição.
Reflexos e brilhos	Placas metálicas e envernizadas criam reflexos que apagam caracteres.
Ângulo de captura	Câmeras posicionadas lateralmente causam distorção perspectiva.
Desgaste e corrosão	Placas antigas têm texto apagado, arranhões e manchas de corrosão.
Sujeira e óleo	Ambientes industriais acumulam poeira, graxa e óleo nas placas.
Baixa resolução	Câmeras de segurança ou smartphones distantes geram imagens desfocadas.
Diversidade de formatos	Cada fabricante adota layout, fonte e dimensões próprias.
Fundo complexo	A placa está inserida em uma cena com texturas metálicas e ruídos.

Visualização das condições simuladas no dataset sintético:

Amostras do Dataset Sintético — Diversidade de Condições




Figura 1 — Amostras do dataset sintético (1.200 imagens) com variações de iluminação, desgaste, sujeira e ângulo.

3. Estratégia Proposta para Leitura da Placa

Etapa 1 — Captura

Imagem capturada por câmera (smartphone, câmera industrial ou webcam) em formato JPG/PNG. A imagem contém a cena completa com o equipamento.

Etapa 2 — Pré-processamento

Redimensionamento para 640px, equalização de contraste (CLAHE), filtro bilateral para redução de ruído, conversão para escala de cinza e binarização adaptativa.

Etapa 3 — Detecção da Placa

Modelo YOLOv8n treinado para localizar a região da placa dentro da cena. Retorna bounding box com coordenadas e confiança da detecção.

Etapa 4 — Recorte e Retificação

Recorte da ROI (Region of Interest) com base no bounding box detectado. Upscale para mínimo de 800px de largura para garantir legibilidade.

Etapa 5 — OCR

Tesseract OCR com múltiplas estratégias de pré-processamento (original, CLAHE, binária) e modos PSM 6 e PSM 11. Retorna a leitura de maior confiança.

Etapa 6 — Parsing e Validação

Expressões regulares extraem campos estruturados (tensão, potência, frequência, grau IP, data, nº série) do texto bruto do OCR.

4. Técnicas e Ferramentas Utilizadas

Técnica / Ferramenta	Finalidade
YOLOv8n (Ultralytics)	Detecção e localização da placa na cena
CLAHE	Equalização adaptativa de contraste por região
Filtro Bilateral	Suavização sem borrar bordas de texto
Binarização Adaptativa	Separação texto/fundo em condições variadas
Operações Morfológicas	Limpeza de ruído na imagem binarizada
Correção de Perspectiva	Retificação de ângulo com warpPerspective
Tesseract OCR (PSM 6/11)	Extração de texto da placa recortada
Regex (re)	Parsing de campos estruturados do texto bruto
OpenCV	Processamento de imagem em todas as etapas
PyTorch + Ultralytics	Backend de inferência do modelo YOLO
editdistance / jiwer	Cálculo de CER/WER para avaliação de OCR

5. Pipeline da Solução — Fluxo End-to-End

O pipeline abaixo mostra as 4 etapas visuais de uma imagem de teste real: detecção com bounding box (97.1%), pré-processamento, recorte da ROI e binarização para OCR.

□ Pipeline End-to-End — test_0098.jpg




Figura 2 — Pipeline End-to-End: (1) Detecção YOLO + BBox, (2) Pré-processado, (3) ROI recortada, (4) Binarizada para OCR.

Etapas de pré-processamento intermediárias:

□ Pipeline de Pré-processamento — Etapas Intermediárias




Figura 3 — Etapas de pré-processamento: Original → CLAHE → Filtro Bilateral → Cinza → Binarização Adaptativa → Binarização Otsu → Pós-morfológica.

6. Critérios de Avaliação da Solução

Métrica	Descrição	Meta	Resultado
Taxa de Detecção	Porcentagem de placas corretamente localizadas pelo YOLO	> 95%	100.0%
mAP@0.50	Mean Average Precision na detecção	> 0.90	Treinado 50 épocas
Score OCR Médio	Confiança média do Tesseract na leitura	> 80%	43.9%
Acurácia Global	Campos 100% corretos por imagem	> 80%	Em ajuste
CER por Campo	Character Error Rate por campo extraído	< 5%	Em ajuste
Tempo de Inferência	Tempo total por imagem (detecção + OCR)	< 500 ms	~10 s*

* Tempo elevado por limitação de CPU no Colab sem GPU; com GPU T4 a detecção é < 50 ms. O OCR multi-estratégia adiciona latência extra.

Dashboard de avaliação gerado automaticamente pelo notebook:




Figura 4 — Dashboard de métricas: Taxa de Detecção 100%, Score OCR médio 43.9%, Tempo médio de inferência 10.189 ms (CPU).

7. Representação Visual da Arquitetura

A arquitetura da solução segue um pipeline sequencial de 6 estágios, desde a entrada da imagem bruta até a saída dos campos estruturados da placa. Cada estágio pode ser executado de forma independente, permitindo substituição de componentes (ex: trocar Tesseract por TrOCR).

■ ENTRADA	Imagem JPG/PNG da cena industrial
■	
■ PRÉ-PROCESSAMENTO	Resize → CLAHE → Filtro Bilateral → Cinza → Binarização
■	
■ DETECÇÃO (YOLOv8n)	Localiza placa → BBox (x1,y1,x2,y2) + Confiança
■	
>■ RECORTE + UPSCALE	Crop da ROI → Escala mínima 800px
■	
■ OCR (Tesseract)	Multi-estratégia (3 pré-proc × 2 PSM) → Melhor confiança
■	
■ PARSING + VALIDAÇÃO	Regex → Campos estruturados (tensão, potência, IP...)
■	
■ SAÍDA	Dict com campos extraídos + scores de confiança

Demo de detecção em placa com condições adversas:




Figura 5 — Demo interativa: placa detectada com reflexo e ângulo de captura.

8. Justificativa Técnica

A estratégia escolhida combina **detecção por rede neural (YOLOv8)** com **OCR baseado em Tesseract**, o que oferece vantagens significativas em relação a abordagens manuais ou mais simples:

Por que YOLOv8 e não detecção por cor/contorno?

Métodos clássicos (Canny, contornos, HSV) falham quando a placa tem cor semelhante ao fundo ou está parcialmente obstruída. O YOLOv8 aprende a reconhecer a estrutura visual da placa (grid, cabeçalho, bordas) independente de cor, sendo robusto a condições adversas.

Por que dataset sintético?

Coletar e anotar milhares de fotos reais de placas industriais é custoso e demorado. A geração sintética controlada (1.200 imagens com variações sistemáticas de iluminação, desgaste e ângulo) permite treinar um detector robusto em horas, com ground truth automático.

Por que multi-estratégia no OCR?

Nenhuma configuração única do Tesseract funciona bem em todas as condições. Testar 3 preprocessamentos (original, CLAHE, binária) com 2 modos PSM e selecionar o de maior confiança aumenta significativamente a taxa de leitura correta.

Por que Regex para parsing?

Os campos da placa seguem padrões previsíveis (tensão: XXX/YYY V, frequência: 50/60 Hz, etc.). Regex é rápido, interpretável e não requer treinamento adicional para estruturar os dados extraídos.

Vantagens sobre abordagem manual

A solução elimina erros de transcrição humana, reduz o tempo de identificação de minutos para segundos e permite rastreabilidade automática em escala, integrando-se a sistemas de gestão de ativos.